

[StyleGAN-NADA reimplementation](#)

StyleGAN-NADA (Non-Adversarial Domain Adaptation) – это zero-shot метод, который модифицирует веса предобученного StyleGAN, используя мультимодальную модель CLIP для переноса генератора из исходного домена в целевой на основе исключительно текстового описания (промпта). Метод был представлен в 2021 году исследователями из Тель-Авивского университета и NVIDIA (Р. Гал, О. Паташник, Х. Марон, А. Бермано, Г. Чечик, Д. Коэн-Ор) в статье «[StyleGAN-NADA: CLIP-Guided Domain Adaptation of Image Generators](#)».

Фундаментальной проблемой классических архитектур GAN является невозможность выхода за пределы определенного домена, то есть того распределения данных, которое модель получила в обучающей выборке. Следовательно, область применения подобных моделей существенно ограничена теми доменами, в которых можно собрать большое количество изображений для обучения. Это значит, что для определенных случаев (например, картины конкретных художников, редкие заболевания, воображаемые сцены) применение стандартных GAN невозможно ввиду малого количества или отсутствия данных для обучения.

Важность исследования авторов, таким образом, состоит в элегантном решении данной проблемы. Кроме того, метод StyleGAN-NADA позволяет генерировать изображения в режиме zero-shot, то есть без обучающей выборки с изображениями в целевом домене. Другими преимуществами метода являются высокая скорость адаптации генератора под определенный домен и гибкость в выборе целевых стилей.

Другим методом, который позволяет менять сгенерированное изображение по текстовому промпту, является StyleCLIP. Суть данного метода состоит в изменении латентного вектора путем минимизации косинусного расстояния между CLIP-представлением сгенерированного с помощью StyleGAN изображения и CLIP-представлением текстового промпта. Однако, как указывают авторы, у StyleCLIP есть два важных ограничения: появление состязательных решений и mode collapse. Первая проблема состоит в том, что вместо необходимых изменений стиля модель начинает создавать шум на уровне пикселей, то есть «взламывать» классификатор CLIP. Вторая проблема связана с потерей уникальности у

генерируемых изображений ввиду того, что косинусный CLIP-лосс никак не штрафует модель за потерю разнообразия генерации.

Для того, чтобы преодолеть ограничения StyleCLIP, авторы StyleGAN-NADA предложили три архитектурных изменения: новую loss-функцию, использование двух генераторов в процессе адаптации модели под целевой стиль, а также отбор k слоёв для оптимизации ограниченного числа параметров нейросети. Остановимся подробнее на каждом изменении.

Для стабилизации кросс-доменной адаптации в методе StyleGAN-NADA применяется стратегия выборочного дообучения, ограничивающая модификацию параметров фиксированным подмножеством из k слоев генератора. Необходимость данного шага обусловлена тем, что разные слои StyleGAN изолированно отвечают за геометрию или текстуру картинки. Оптимизация всей сети может быть избыточной и ведет к разрушению пространственной структуры объектов, тогда как ограничение числа адаптируемых слоев величиной k выступает регуляризатором, позволяющим сохранить базовые черты исходного изображения. Процедура отбора базируется на анализе чувствительности и выглядит следующим образом:

- 1) Авторы сэмпляют N векторов из пространства W и конвертируют их в пространство $W+$ путем дублирования одного и того же вектора для каждого из 18-и слоев;
- 2) Замораживаются все аффинные слои, toRGB-слои и маппинг-сеть;
- 3) После этого происходит M итераций по оптимизации каждого из латентных векторов с помощью стандартного CLIP-loss;
- 4) Отбираются те k слоев, для которых латентный вектор изменился сильнее всего.

Для устранения проблемы состязательного шума и потери разнообразия генерации авторы StyleGAN-NADA отказываются от стандартного CLIP-loss и вводят новую направленную функцию потерь. Суть данного метода состоит в том, что вместо вычисления расстояния между конкретным изображением и текстовым промптом, модель сопоставляет векторы изменений в визуальном и текстовом пространствах. Процедура расчета выглядит следующим образом:

- 1) Сначала вычисляется текстовый вектор сдвига как разность между CLIP-представлениями целевого и исходного текстовых описаний;

- 2) Затем вычисляется визуальный вектор сдвига как разность между эмбедингами картинок, обучаемым и замороженным генераторами из одного латентного вектора. Таким образом, задача замороженного генератора состоит в создании изображения из исходного домена для каждого латентного кода;
- 3) Итоговая функция потерь минимизирует косинусное расстояние между этими двумя векторами направлений.

Поскольку данный лосс требует параллельности векторов изменений, он не заставляет модель оптимизировать пиксельный шум для обмана классификатора. Кроме того, такой подход никак не привязывает генерацию к одной целевой точке, что эффективно решает проблему потери уникальности и сохраняет исходное разнообразие объектов.